

**Diseño de un algoritmo de aprendizaje profundo para estimar síntomas depresivos a partir
de hábitos de tiempo de pantalla y sueño en adolescentes**

Yuliana Arango López

Tecnológica del Oriente

Electiva - Inteligencia Artificial Avanzada

Carlos Carrascal Avendaño

26 de julio de 2026

Resumen

Este informe presenta el diseño, la implementación y la evaluación de un algoritmo de aprendizaje profundo orientado a estimar el riesgo de síntomas depresivos en adolescentes a partir de sus hábitos de tiempo de pantalla y sueño, siguiendo la estrategia de Aprendizaje Basado en Retos (ABR). Se utilizó un conjunto de datos derivado de un estudio longitudinal con 4.810 adolescentes suecos (Hökby et al., 2025), evaluados mediante el Inventario de Depresión de Beck-II (BDI-II). Se diseñó una red neuronal densa de tres capas ocultas (64-32-16 neuronas), entrenada con el optimizador Adam y regularizada mediante Dropout y parada temprana, alcanzando un error absoluto medio (MAE) de aproximadamente 3.2 puntos sobre una escala de 0 a 63, sin evidencia de sobreajuste. El informe también discute la aplicabilidad del aprendizaje por refuerzo en problemas industriales complejos, y examina las implicaciones éticas y de equidad de aplicar modelos predictivos a datos de salud mental, incluyendo riesgos de sesgo demográfico, transparencia y uso indebido. Se concluye que, si bien el modelo demuestra viabilidad técnica, su aplicación en contextos reales exige salvaguardas éticas rigurosas y no debe sustituir el juicio clínico profesional.

Palabras clave: aprendizaje profundo, redes neuronales, salud mental, ética en inteligencia artificial, aprendizaje por refuerzo.

1. Introducción y planteamiento del problema

1.1 Contexto y relevancia

La salud mental adolescente es reconocida como una de las principales causas de carga de enfermedad en la población de 10 a 19 años a nivel mundial. Paralelamente, el uso de pantallas — redes sociales, videojuegos, mensajería y contenido en streaming— se ha convertido en una de las actividades cotidianas más extendidas entre los adolescentes, superando frecuentemente las recomendaciones internacionales de salud pública, como el límite de menos de dos horas diarias sugerido por la Organización Mundial de la Salud para grupos de edad de 5 a 17 años (Chaput et al., 2020).

La literatura científica reciente ha documentado de manera consistente una asociación entre el tiempo de pantalla, la calidad y duración del sueño, y la presencia de síntomas depresivos en adolescentes, aunque los tamaños de efecto reportados suelen ser pequeños y el mecanismo causal continúa en discusión (Hökby et al., 2025). Este escenario constituye un problema complejo y de alto impacto potencial para la inteligencia artificial: un problema donde las variables involucradas son numerosas, las relaciones entre ellas no son estrictamente lineales, y una detección temprana —incluso aproximada— podría facilitar intervenciones preventivas en contextos escolares o clínicos con recursos limitados.

1.2 Justificación de la selección del problema

Se seleccionó el problema de estimar síntomas depresivos a partir de hábitos de pantalla y sueño por tres razones. Primero, su relevancia social y actualidad: la vigilancia epidemiológica de la salud mental adolescente es una prioridad declarada por organismos de salud pública en distintos países, incluyendo recientes recomendaciones oficiales suecas sobre el uso de pantallas en adolescentes (Chaput et al., 2020; Hökby et al., 2025). Segundo, la disponibilidad de un conjunto

de datos robusto, longitudinal y de tamaño considerable ($N = 4.810$), que permite entrenar y evaluar un modelo de aprendizaje profundo de manera rigurosa. Tercero, el problema ejemplifica de forma clara los retos técnicos y éticos que enfrenta cualquier aplicación de IA en salud: la necesidad de balancear el desempeño predictivo con la equidad, la transparencia y la responsabilidad en el uso de los resultados (Timmons et al., 2023).

Es importante precisar, sin embargo, que la solución propuesta en este informe no constituye una herramienta diagnóstica. Se trata de un ejercicio académico que busca demostrar la aplicabilidad de técnicas de aprendizaje profundo a un problema de impacto social, evaluando de manera crítica tanto sus capacidades como sus límites.

2. Revisión de la literatura

2.1 Tiempo de pantalla, sueño y depresión en la adolescencia

El estudio que sirve de base empírica a este trabajo (Hökby et al., 2025) analizó datos de tres olas longitudinales recolectados entre 2016 y 2019 en 4.810 adolescentes suecos de 12 a 16 años, midiendo el tiempo de pantalla, cuatro facetas del sueño (calidad, duración, cronotipo y jetlag social) y los síntomas depresivos mediante el BDI-II, un instrumento clínico validado de 21 ítems cuya puntuación total oscila entre 0 y 63 puntos, con un punto de corte de más de 13 puntos para depresión leve. Los resultados mostraron que el tiempo de pantalla predijo de manera significativa el deterioro de casi todas las facetas del sueño, y que, particularmente entre las adolescentes mujeres, este deterioro del sueño mediaba entre el 38% y el 57% del efecto depresivo del tiempo de pantalla.

Estos hallazgos son consistentes con estudios previos realizados en otros contextos culturales. Un estudio prospectivo con 9.538 adolescentes estadounidenses del Adolescent Brain Cognitive Development (ABCD) Study encontró que el tiempo total de pantalla se asociaba de forma

significativa con síntomas depresivos, y que esta asociación variaba según el grupo étnico analizado. Estudios transversales realizados con adolescentes de Malasia y con estudiantes brasileños reportaron igualmente relaciones directas y significativas entre mayor tiempo de pantalla y mayores niveles de síntomas depresivos, reforzando la generalización del fenómeno más allá de un único contexto geográfico o cultural.

2.2 Fundamentos técnicos del aprendizaje profundo

El aprendizaje profundo (deep learning) es una familia de algoritmos de aprendizaje automático basados en redes neuronales artificiales de múltiples capas, capaces de aprender representaciones jerárquicas de los datos sin necesidad de ingeniería manual de características (LeCun et al., 2015). Una red neuronal densa (fully-connected) transforma progresivamente los datos de entrada mediante combinaciones lineales ponderadas por pesos entrenables, seguidas de funciones de activación no lineales, como la Unidad Lineal Rectificada (ReLU), que permiten al modelo aproximar relaciones complejas y no lineales entre las variables (LeCun et al., 2015; Goodfellow et al., 2016).

El entrenamiento de estas redes se realiza mediante retropropagación del error y algoritmos de optimización basados en descenso de gradiente. Entre estos, el optimizador Adam (Adaptive Moment Estimation) ha demostrado ser especialmente eficiente y estable, al combinar estimaciones adaptativas de los momentos de primer y segundo orden del gradiente para ajustar automáticamente la tasa de aprendizaje de cada parámetro (Kingma & Ba, 2015).

Uno de los principales riesgos al entrenar redes con muchos parámetros es el sobreajuste (overfitting): el modelo memoriza patrones específicos, incluyendo ruido, del conjunto de entrenamiento, perdiendo capacidad de generalización sobre datos nuevos. Srivastava et al. (2014) propusieron la técnica de Dropout, que consiste en desactivar aleatoriamente un porcentaje de

neuronas durante cada paso de entrenamiento, forzando a la red a no depender excesivamente de combinaciones específicas de neuronas y mejorando su capacidad de generalización. Esta técnica, junto con la detención temprana del entrenamiento (early stopping) cuando el error de validación deja de mejorar, constituye una de las estrategias de regularización más utilizadas en la práctica (Srivastava et al., 2014).

2.3 Aprendizaje por refuerzo y su aplicabilidad en problemas industriales complejos

A diferencia del aprendizaje supervisado empleado en este proyecto, el aprendizaje por refuerzo (reinforcement learning, RL) aborda problemas de decisión secuencial, en los que un agente aprende una política óptima de acción mediante prueba y error, interactuando con un entorno y recibiendo señales de recompensa. Diversas revisiones sistemáticas han documentado aplicaciones exitosas de RL en sectores industriales complejos: control de procesos químicos, programación de producción en refinerías, mantenimiento predictivo y optimización logística, entre otros (Kegyes et al., 2021).

El RL resulta particularmente adecuado para entornos de alta dimensionalidad, no linealidad e incertidumbre, donde los métodos de control óptimo tradicionales resultan insuficientes. Sin embargo, su adopción industrial todavía enfrenta limitaciones relevantes, como la ineficiencia en el uso de datos, la ausencia de garantías formales de estabilidad, y la necesidad de simuladores representativos del entorno real (Kegyes et al., 2021). En el dominio de la salud mental específicamente, el aprendizaje por refuerzo tiene potencial aplicabilidad en la personalización dinámica de intervenciones digitales, por ejemplo, ajustar el momento y contenido de notificaciones de una aplicación de bienestar según la respuesta del usuario, aunque su uso en este campo es todavía incipiente comparado con el aprendizaje supervisado utilizado en este proyecto.

2.4 Consideraciones éticas y de equidad en IA aplicada a salud mental

La literatura advierte de manera consistente que los algoritmos de aprendizaje automático nunca son completamente objetivos: las decisiones de diseño, como qué variables incluir, cómo definir el resultado a predecir o qué datos de entrenamiento se utilizan, incorporan elecciones y supuestos que reflejan valores y compromisos éticos (Holm, 2024). En el contexto específico de la salud mental, Timmons et al. (2023) documentan que el sesgo algorítmico puede originarse en datos de entrenamiento poco representativos de ciertos grupos demográficos, lo que puede traducirse en predicciones sistemáticamente menos precisas, o más dañinas, para esos grupos.

Un ejemplo relevante para este proyecto: el mismo estudio de origen de los datos (Hökby et al., 2025) excluyó explícitamente a los participantes con género no binario por razones metodológicas, y encontró diferencias considerables en el efecto estudiado entre niños y niñas. Un modelo entrenado sin distinguir estas diferencias de género corre el riesgo de generar predicciones menos precisas, y potencialmente menos útiles o más dañinas, para subgrupos específicos de la población. Adicionalmente, el uso de modelos predictivos de riesgo de depresión plantea preguntas sobre la confidencialidad de los datos, el consentimiento informado, y las consecuencias de un falso positivo o falso negativo en un contexto escolar o clínico (Timmons et al., 2023; Holm, 2024).

3. Diseño del algoritmo

3.1 Datos de entrada

El modelo utiliza como variables predictoras el tiempo de pantalla diario y variables relacionadas con el hábito de sueño (calidad, duración semanal promedio), disponibles en una versión procesada y lista para aprendizaje automático del conjunto de datos original de Hökby et al. (2025), publicada en la plataforma Kaggle bajo el nombre "Screen Time vs Mental Health (ML-Ready)". La variable objetivo es la puntuación BDI-II, tratada como una variable continua (regresión), dado que

conserva más información que una clasificación binaria simple entre presencia y ausencia de depresión.

3.2 Arquitectura de la red neuronal

Se diseñó una red neuronal densa de tipo feedforward compuesta por: (a) una capa de entrada que recibe las variables de tiempo de pantalla y sueño estandarizadas; (b) tres capas ocultas densas de 64, 32 y 16 neuronas respectivamente, cada una con activación ReLU; (c) capas de Dropout del 30% y 20% intercaladas entre las dos primeras capas ocultas; y (d) una capa de salida de una sola neurona con activación lineal, que produce el valor numérico predicho de la puntuación BDI-II.

La reducción progresiva del número de neuronas por capa (64 a 32 a 16) sigue el patrón habitual en arquitecturas densas para problemas tabulares de tamaño moderado, permitiendo que la red aprenda representaciones cada vez más abstractas y compactas de los datos de entrada antes de producir la predicción final (LeCun et al., 2015).

3.3 Funciones de activación y optimización

Se utilizó la función ReLU (Rectified Linear Unit) en todas las capas ocultas, por su eficiencia computacional y porque mitiga el problema del desvanecimiento del gradiente que afecta a otras funciones como la sigmoide (LeCun et al., 2015). La capa de salida emplea activación lineal, apropiada para tareas de regresión donde la variable objetivo no está acotada a un rango fijo.

Para la optimización se seleccionó Adam, con una tasa de aprendizaje inicial de 0.001, por su comprobada eficiencia y estabilidad en un amplio rango de problemas de aprendizaje profundo (Kingma & Ba, 2015). La función de pérdida utilizada fue el error cuadrático medio (MSE), estándar para tareas de regresión, mientras que el error absoluto medio (MAE) se empleó como métrica de evaluación complementaria por su interpretabilidad directa en la misma escala que la variable objetivo (puntos BDI-II).

3.4 Técnicas de regularización

Dado el riesgo de sobreajuste inherente a redes con múltiples capas y parámetros entrenables, se incorporaron dos técnicas de regularización, justificadas en la literatura revisada: Dropout (Srivastava et al., 2014), aplicado con tasas de 30% y 20% tras las dos primeras capas ocultas, y detención temprana (early stopping), que interrumpe el entrenamiento cuando el error de validación deja de mejorar durante 10 épocas consecutivas, restaurando los pesos del mejor punto observado.

4. Implementación y pruebas

4.1 Entorno y herramientas

El algoritmo se implementó en Python, utilizando el framework TensorFlow/Keras para la construcción y entrenamiento de la red neuronal, scikit-learn para el preprocesamiento de datos (partición train/test, estandarización), y Google Colab como entorno de ejecución en la nube, lo que permitió descargar el conjunto de datos directamente desde Kaggle mediante la librería kagglehub, sin necesidad de almacenamiento manual de archivos.

4.2 Preprocesamiento de los datos

Se aplicó un proceso de limpieza (eliminación de valores nulos), codificación de variables categóricas mediante LabelEncoder, y estandarización de las variables numéricas mediante StandardScaler, ajustado únicamente sobre el conjunto de entrenamiento para evitar fuga de información (data leakage) hacia el conjunto de prueba. Los datos se dividieron en un 80% para entrenamiento y un 20% para prueba, reservando adicionalmente un 20% del conjunto de entrenamiento para validación durante el proceso de ajuste de los pesos.

4.3 Proceso de entrenamiento

El modelo se entrenó durante un máximo de 100 épocas, con un tamaño de lote (batch size) de 32 muestras, deteniéndose de manera anticipada alrededor de la época 38 gracias al mecanismo de early stopping, al no observarse mejoras adicionales en el error de validación.

4.4 Resultados obtenidos

Tras el entrenamiento, el modelo alcanzó un error absoluto medio (MAE) de aproximadamente 3.2 puntos sobre la escala BDI-II (0 a 63 puntos), tanto en el conjunto de entrenamiento como en el de validación. Las curvas de pérdida (loss) y de MAE mostraron una convergencia rápida durante las primeras 10 épocas, seguida de una estabilización sostenida hasta el final del entrenamiento. Un hallazgo relevante es que las curvas de entrenamiento y de validación se mantuvieron prácticamente superpuestas durante todo el proceso, sin la divergencia característica del sobreajuste, lo que sugiere que las técnicas de regularización aplicadas (Dropout y early stopping) cumplieron efectivamente su función, y que el modelo generaliza razonablemente bien a datos no vistos durante el entrenamiento.

5. Evaluación y reflexión

5.1 Desempeño técnico

El MAE obtenido (aproximadamente 3.2 puntos) representa un error moderado en relación con el rango total de la escala BDI-II (0 a 63 puntos) y con el punto de corte clínico de depresión leve (más de 13 puntos; Hökby et al., 2025). Esto significa que, en promedio, la predicción del modelo se desvía en aproximadamente 3 puntos del puntaje real reportado por cada adolescente. Si bien esta magnitud de error podría ser aceptable para una herramienta de cribado poblacional o de alerta temprana, no sería suficiente para un uso diagnóstico individual, donde errores de esa magnitud podrían llevar a clasificar erróneamente a un adolescente cercano al punto de corte clínico.

Es importante señalar que el propio estudio de origen (Hökby et al., 2025) reportó tamaños de efecto pequeños entre tiempo de pantalla, sueño y depresión (coeficientes beta estandarizados entre 0.02 y 0.30), lo que sugiere que existe un límite razonable, dado por la propia naturaleza multicausal de la depresión, a la precisión que cualquier modelo basado únicamente en estas dos variables puede alcanzar, independientemente de la sofisticación de la arquitectura de red utilizada.

5.2 Consideraciones éticas y de equidad

Siguiendo el marco de evaluación de sesgos propuesto por Timmons et al. (2023), se identifican al menos tres riesgos éticos relevantes en este proyecto. Primero, un riesgo de representatividad: el conjunto de datos original proviene de una población específica (adolescentes suecos de Estocolmo), por lo que las predicciones del modelo no necesariamente se generalizan a adolescentes de otros países, culturas o niveles socioeconómicos, y su aplicación directa fuera de ese contexto sin validación adicional sería éticamente cuestionable. Segundo, un riesgo de equidad de género: el estudio de origen documentó diferencias sustanciales en el efecto mediador del sueño entre niños y niñas, y excluyó a personas de género no binario; un modelo que no module sus predicciones por estas diferencias corre el riesgo de ser menos preciso, y potencialmente menos útil o más dañino, para subgrupos específicos. Tercero, un riesgo de uso indebido: como advierte Holm (2024), ningún resultado algorítmico en salud mental es completamente objetivo, y una puntuación predicha por un modelo nunca debería sustituir la evaluación de un profesional clínico, ni utilizarse como único criterio para decisiones que afecten a un adolescente, por ejemplo, una derivación a un especialista o una notificación a los padres.

5.3 Limitaciones

Entre las limitaciones de este trabajo se destacan: (a) el modelo utiliza únicamente dos dimensiones (pantalla y sueño) del fenómeno depresivo, ignorando otros factores relevantes documentados en

la literatura, como el estrés académico, las relaciones sociales o el estatus socioeconómico; (b) el conjunto de datos es transversal y deriva de un estudio observacional, por lo que el modelo captura asociaciones estadísticas y no relaciones causales; (c) no se realizó una evaluación de equidad desagregada por subgrupos, por ejemplo, comparando el error del modelo entre niños y niñas, lo cual sería un paso necesario antes de considerar cualquier aplicación real del modelo; y (d) la arquitectura y los hiperparámetros no fueron optimizados de manera exhaustiva, por ejemplo, mediante búsqueda en grilla o validación cruzada, por lo que el desempeño reportado representa un punto de partida razonable, pero no necesariamente el óptimo alcanzable.

5.4 Trabajo futuro

Como líneas de trabajo futuro se proponen: incorporar variables adicionales documentadas en la literatura, como actividad física, relaciones sociales o uso de redes sociales específicas; realizar una evaluación de equidad desagregada por género y edad; explorar arquitecturas alternativas como redes recurrentes, dado que los datos de origen tienen una estructura longitudinal de tres olas que este proyecto no explotó completamente; y, en una fase posterior, explorar el uso de aprendizaje por refuerzo para personalizar dinámicamente intervenciones digitales de bienestar, siempre bajo supervisión clínica y con salvaguardas éticas explícitas.

6. Conclusiones

Este proyecto demostró la viabilidad técnica de utilizar una red neuronal profunda densa, con Dropout, early stopping y el optimizador Adam, para estimar puntuaciones de síntomas depresivos a partir de hábitos de tiempo de pantalla y sueño en una muestra representativa de adolescentes. El modelo alcanzó un error absoluto medio de aproximadamente 3.2 puntos, con evidencia clara de buena generalización, es decir, ausencia de sobreajuste. Sin embargo, el ejercicio también evidenció que el desempeño técnico por sí solo es insuficiente para justificar la aplicación de este

tipo de modelos en contextos reales de salud mental: las consideraciones de representatividad, equidad de género y uso responsable son igual de determinantes que la precisión del modelo. En línea con la literatura revisada (Holm, 2024; Timmons et al., 2023), se concluye que los algoritmos de aprendizaje profundo aplicados a salud mental deben entenderse como herramientas de apoyo a la decisión humana, nunca como sustitutos del juicio clínico profesional, y que su desarrollo responsable exige incorporar la evaluación ética desde las etapas tempranas del diseño, y no como una reflexión posterior a la implementación.

Referencias

- Chaput, J.-P., Willumsen, J., Bull, F., Chou, R., Ekelund, U., Firth, J., Jago, R., Ortega, F. B., & Katzmarzyk, P. T. (2020). 2020 WHO guidelines on physical activity and sedentary behaviour for children and adolescents aged 5-17 years: summary of the evidence. *International Journal of Behavioral Nutrition and Physical Activity*, 17, Article 141. <https://doi.org/10.1186/s12966-020-01037-z>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Hökby, S., Alvarsson, J., Westerlund, J., Carli, V., & Hadlaczky, G. (2025). Adolescents' screen time displaces multiple sleep pathways and elevates depressive symptoms over twelve months. *PLOS Global Public Health*, 5(4), Article e0004262. <https://doi.org/10.1371/journal.pgph.0004262>
- Holm, S. (2024). Ethical trade-offs in AI for mental health. *Frontiers in Psychiatry*, 15, Article 1407562. <https://doi.org/10.3389/fpsyt.2024.1407562>
- Kegyes, Z., Süle, Z., & Abonyi, J. (2021). The applicability of reinforcement learning methods in the development of Industry 4.0 applications. *Complexity*, 2021, Article 7179374. <https://doi.org/10.1155/2021/7179374>
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *Proceedings of the 3rd International Conference on Learning Representations (ICLR 2015)*.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444. <https://doi.org/10.1038/nature14539>
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929-1958.

Timmons, A. C., Duong, J. B., Simo Fiallo, N., Lee, T., Vo, H. P. Q., Ahle, M. W., Comer, J. S., Brewer, L. C., Frazier, S. L., & Chaspari, T. (2023). A call to action on assessing and mitigating bias in artificial intelligence applications for mental health. *Perspectives on Psychological Science*, 18(5), 1062-1096. <https://doi.org/10.1177/17456916221134490>